MINISTERUL EDUCAȚIEI ȘI CERCETĂRII AL REPUBLICII MOLDOVA
Universitatea Tehnică a Moldovei
Facultatea Calculatoare, Informatică şi Microelectronică
Departamentul Ingineria Sistemelor

RAPORT TEHNIC

la concursul „AI Cyber Defense Challenge” – ZTS, ediția a XIII-a

Tema: Detectarea atacurilor cibernetice în traficul de rețea prin învățare automată

Echipa „Eunoia”: **Drangoi Karina, Secrieru Maxim**

Organizator: **OSACE × RSI × Universitatea din Craiova**

Craiova 2026

INTRODUCERE

Previzualizare: cifrele provin dintr-o repetiție pe setul public UNSW-NB15 adus la formatul concursului.

Scopul: un model care deosebește traficul de rețea normal de atacuri pe trei niveluri: detectarea atacului, recunoașterea tipului de atac și izolarea tipurilor de atac absente la antrenare. Fiecare rând este un flux de rețea cu 39 de caracteristici numerice, train ~141 700 rânduri, test ~38 650 rânduri.

Tabelul 1.1 – Nivelurile concursului

Nivel	Sarcina	Fișier	Metrica	Pondere
1	Normal (0) / Atac (1)	id,label	F1 binar	20%
2	10 clase: Normal + 9 atacuri	id,attack_cat	Macro F1	30%
3	7 clase cunoscute + Unknown	id,attack_cat,unknown_score	0,6·Macro F1 + 0,4·AUROC	30%

1 PREGĂTIREA DATELOR

Au fost folosite toate cele 39 de caracteristici, fără id. Valorile lipsă, ne-numerice sau infinite au devenit 0. Modelele pe arbori nu cer scalare, de aceea datele nu au fost normalizate pentru clasificare. Au fost adăugate 8 caracteristici derivate: raportul octeților și al pachetelor sursă/destinație, octeți per pachet pe fiecare direcție, volumul total, perechea TTL sursă·1000 + destinație (amprenta gazdei), indicatorul „destinația nu răspunde” și raportul încărcărilor. Clasele rare (Worms, Shellcode, Backdoor, Analysis au de zeci de ori mai puține exemple decât Normal) au primit ponderi w = (n_max / n_c)^0,5, care le ridică fără să strice precizia pe clasele mari. Pentru semnalul kNN de la nivelul 3 datele au fost logaritmate (log1p) și standardizate.

2 MODELELE PE NIVELURI

Nivelul 1. LightGBM (până la 1200 de arbori, rata 0,05, 63 de frunze, oprire timpurie) cu validare încrucișată stratificată în 5 părți. Predicția pe test este media celor cinci modele, iar pragul de decizie a fost ales pe predicțiile out-of-fold pentru F1 maxim (0,49).

Nivelul 2. Același model, multiclasă, cu ponderile de clasă. Pe predicțiile out-of-fold a fost căutat câte un multiplicator al probabilității fiecărei clase care maximizează macro F1. Multiplicatorii mută frontierele spre clasele rare și cresc macro F1 de la 0,6143 la 0,6235.

Nivelul 3. Clasificatorul pentru cele 7 clase cunoscute este construit ca la nivelul 2. Scorul unknown_score este media ponderată a rangurilor (în [0, 1]) a patru semnale: 1 − probabilitatea maximă, entropia distribuției de probabilitate, distanța medie la cei mai apropiați 10 vecini din train și un clasificator train-vs-test antrenat fără etichete (train și test diferă doar prin clasele noi, deci fluxurile care „arată a test” sunt candidați la Unknown). Ponderile au fost alese printr-o simulare leave-one-class-out: fiecare clasă de atac a fost scoasă pe rând din train, rărită la ~2% în validare, iar combinația cu AUROC mediu maxim a fost păstrată. Ca Unknown sunt marcate cele mai suspecte 1,7% fluxuri din test, fracție estimată din diferența dintre train-ul nivelului 3 (~139 300 rânduri) și cel al nivelului 2 (~141 700 rânduri).

3 EXPERIMENTE ȘI TESTARE

Toate modelele au fost verificate prin validare încrucișată în 5 părți. Înainte de concurs, programul a fost repetat pe setul public UNSW-NB15 adus la aceleași coloane, iar fișierele au fost punctate local cu metricile platformei.

Tabelul 3.1 – Rezultatele pe niveluri (repetiție)

Nivel	Validare (out-of-fold)	Scor pe test	Timp, s
1 – F1 binar	0,9601	0,9618	38.5
2 – Macro F1	0,6143 → 0,6235	0,6299	139.3
3 – compozit	AUROC simulat 0,8815	0,7101 blend, 0,7162 entropie	242.2

La nivelul 2 cele mai slabe clase sunt Backdoor, Analysis și DoS: au adesea vectori de caracteristici identici cu etichete diferite, deci niciun model nu le separă complet. **Ce nu a funcționat:** regresia logistică din starter kit (mult sub arbori), numărarea duplicatelor exacte dintre train și test (AUROC ≈ 0,47), distanța kNN singură (sub hazard pentru clasele noi asemănătoare cu DoS și Exploits, de aceea ponderea ei a fost redusă). Ponderile din simulare nu s-au transferat perfect, entropia singură fiind la fel de bună, de aceea la nivelul 3 au fost trimise ambele variante.

CONCLUZII

Cel mai mult au contat boosting-ul pe arbori, ponderarea claselor rare și ajustarea pragurilor pe predicții out-of-fold, nu pe clasament. La open-set, entropia clasificatorului a fost cel mai stabil semnal. Limita principală vine din date: fluxurile Analysis, Backdoor și DoS cu caracteristici identice nu pot fi separate, iar clasele noi seamănă tocmai cu acestea.

Utilizarea AI: Am folosit AI-ul Claude de la Anthropic pentru ghidare.

BIBLIOGRAFIE

1. https://hackathon.osace.ro/guide
2. https://lightgbm.readthedocs.io/en/stable/
3. [N. Moustafa, J. Slay. UNSW-NB15: a comprehensive data set for network intrusion detection systems. MilCIS, 2015.]
4. [D. Hendrycks, K. Gimpel. A Baseline for Detecting Misclassified and Out-of-Distribution Examples. ICLR, 2017.]