MINISTERUL EDUCAȚIEI ȘI CERCETĂRII AL REPUBLICII MOLDOVA
Universitatea Tehnică a Moldovei
Facultatea Calculatoare, Informatică şi Microelectronică
Departamentul Ingineria Sistemelor

RAPORT TEHNIC

la concursul „AI Cyber Defense Challenge” – ZTS, ediția a XIII-a

Tema: Detectarea atacurilor cibernetice în traficul de rețea prin învățare automată

Echipa „Eunoia”: **Drangoi Karina, Secrieru Maxim**

Organizator: **OSACE × RSI × Universitatea din Craiova**

Craiova 2026

INTRODUCERE

Scopul: un model care deosebește traficul de rețea normal de atacuri pe trei niveluri: detectarea atacului, recunoașterea tipului de atac și izolarea tipurilor de atac absente la antrenare. Fiecare rând este un flux de rețea cu 39 de caracteristici numerice (train ~141 700 rânduri, test ~38 650 rânduri pe nivel). Metricile sunt F1 binar (nivelul 1), macro F1 pe 10 clase (nivelul 2) și 0,6·macro F1 pe 8 etichete + 0,4·AUROC pentru Unknown (nivelul 3).

1 PREGĂTIREA DATELOR

Au fost folosite toate cele 39 de caracteristici, fără id, plus 8 derivate: raportul octeților și al pachetelor sursă/destinație, octeți per pachet pe fiecare direcție, volumul total, perechea TTL sursă·1000 + destinație, indicatorul „destinația nu răspunde” și raportul încărcărilor. Valorile lipsă sau infinite au devenit 0, iar modelele pe arbori nu au cerut scalare. Analiza datelor a arătat că nu există niciun rând duplicat, deși octeții și pachetele sunt numere întregi intacte: perturbate sunt doar durata și rata fluxului. Clasele rare au primit ponderi w = (n_max / n_c)^p cu p între 0,5 și 1, iar pentru kNN datele au fost logaritmate și standardizate.

2 MODELELE PE NIVELURI

Toate modelele au fost evaluate prin validare încrucișată stratificată în 5 părți, iar fiecare decizie (combinație, prag, ponderi pe clase) a fost luată pe predicțiile out-of-fold, nu pe clasament. Antrenarea a rulat pe un calculator cu 28 de nuclee și o placă RTX 4070: XGBoost și CatBoost pe GPU, restul pe CPU.

Nivelul 1. Au fost comparate LightGBM, ExtraTrees, RandomForest, XGBoost, CatBoost și HistGradientBoosting. Combinația aleasă greedy pe F1 out-of-fold a fost ExtraTrees (două configurații) + LightGBM, cu pragul optimizat pe aceleași predicții (0,475).

Nivelul 2. Modele de bază: trei variante LightGBM (ponderi de clasă 0,5 / 0,75 / 1), ExtraTrees, RandomForest și XGBoost. Peste probabilitățile lor out-of-fold (70 de valori pe rând, în logaritm) a fost antrenat un al doilea LightGBM mic (stacking), tot în 5 părți, care învață ce model să creadă pentru fiecare clasă. Predicția finală este media stacking ×2 + LightGBM ×2 + ExtraTrees, urmată de câte un multiplicator pe clasă ales prin optimizare pe coordonate pentru macro F1.

Nivelul 3. Clasificatorul pentru cele 7 clase cunoscute este construit ca la nivelul 2, cu XGBoost și CatBoost pe GPU în stacking. Scorul unknown_score combină ranguri ale entropiei probabilităților, distanței kNN până la train și ale unui clasificator train-vs-test fără etichete, cu ponderi alese printr-o simulare leave-one-class-out (fiecare clasă de atac scoasă pe rând din train). Pasul decisiv a fost pseudo-etichetarea: cele mai suspecte 12% din fluxurile de test sunt tratate ca Unknown și separate de train de un model antrenat încrucișat, iar scorul final este media rangurilor celor două scoruri. Un model cu 8 clase, antrenat cu aceste rânduri ca a opta clasă, contribuie cu 30% la scorul final. Ca Unknown sunt marcate primele ~1,7% fluxuri (650–657), fracție estimată din diferența dintre train-ul nivelului 3 (~139 300 rânduri) și cel al nivelului 2 (~141 700 rânduri) și confirmată de ruptura de pantă a scorului.

3 EXPERIMENTE ȘI TESTARE

Tabelul 3.1 – Evoluția scorurilor pe niveluri

Nivel	Prima variantă	Varianta finală	Validare finală	Clasament
1 – F1 binar	95,76%	ExtraTrees + LightGBM	0,9579	95,88%
2 – Macro F1	59,66%	stacking + LightGBM + ET	0,6200	61,17%
3 – compozit	75,83%	stacking + pseudo-etichetare	F1 cunoscute 0,6958	83,94%

Diferențele de peste ~0,5 puncte pe validare s-au regăsit pe test, cele sub 0,2 nu. **Ce nu a funcționat:** caracteristicile de frecvență, mai multe seed-uri pentru același model și combinațiile cu 9–11 modele (câștig sub zgomot), CatBoost pe CPU (prea lent pe 10 clase), semnăturile pe valori exacte ale octeților (aceleași valori apar la Exploits, DoS, Analysis și Backdoor, acuratețe leave-one-out 47%) și pseudo-etichetarea în două iterații (82,75% față de 83,40%, erorile se amplifică).

CONCLUZII

Soluția a obținut 95,88% la nivelul 1, 61,17% la nivelul 2 și 83,94% la nivelul 3. Cel mai mult au contat trei idei. Prima este combinarea unor modele de tipuri diferite (boosting și arbori aleatori), care greșesc în locuri diferite: la nivelul 1 a adus +0,12 puncte, iar stacking-ul peste probabilitățile lor a adus +0,7 puncte la nivelul 2. A doua este luarea tuturor deciziilor (praguri, ponderi pe clase, combinații) pe predicții out-of-fold, nu pe clasament, ceea ce a făcut ca scorurile de pe test să urmeze fidel validarea. A treia, și cea mai importantă, este pseudo-etichetarea pe test pentru atacurile noi: ea a ridicat nivelul 3 de la 75,83% la 83,40% într-o singură submisie, pentru că tipurile noi de atac formează grupuri proprii, ușor de separat odată ce modelul vede exemple din test.

Analiza erorilor arată unde este limita. La nivelul 3, partea Unknown este practic rezolvată: proporțiile claselor dispărute din train prevăd circa 655 de fluxuri noi, iar detectorii noștri sunt de acord asupra a 647 dintre primele 657. Pierderea rămasă vine din clasele cunoscute Backdoor (F1 0,24) și DoS (0,50), confundate cu Exploits. Am verificat că nu este o slăbiciune a modelului: fluxuri cu exact aceiași octeți, pachete și TTL apar cu etichete diferite, iar nici semnăturile exacte, nici mai multe modele, nici alte ponderi nu au depășit 0,696 pe aceste clase. Limita este deci în date, iar o îmbunătățire reală ar cere informații care lipsesc din cele 39 de coloane, de exemplu conținutul pachetelor sau protocolul și serviciul.

Ca lecție practică, diferențele de peste 0,5 puncte pe validare s-au confirmat pe test, cele sub 0,2 nu, iar rularea modelelor pe un calculator cu GPU a redus antrenarea XGBoost și CatBoost de la zeci de minute la două–trei minute, lăsând timp pentru mai multe experimente.

Utilizarea AI: Am folosit AI pentru structurarea codului și a raportului.

BIBLIOGRAFIE

1. https://hackathon.osace.ro/guide
2. https://lightgbm.readthedocs.io/en/stable/
3. [D. H. Wolpert. Stacked generalization. Neural Networks, 5(2), 1992.]
4. [D. Hendrycks, K. Gimpel. A Baseline for Detecting Misclassified and Out-of-Distribution Examples. ICLR, 2017.]