AI Cyber Defense Challenge — Raport tehnic

Echipa: Eunoia · Membri: Drangoi Karina, Secrieru Maxim · ZTS XIII, 8 noiembrie 2026

1. Pregătirea datelor

Am folosit toate cele 39 de caracteristici numerice (fără id). Valorile lipsă sau ne-numerice → 0, valorile infinite → 0. Fiind modele pe arbori, nu am scalat datele pentru clasificare. Am adăugat 8 caracteristici derivate care exprimă interacțiuni greu de învățat din separări simple: raport octeți src/dst, raport pachete, octeți per pachet (src și dst), volum total, perechea TTL src·1000+dst (amprenta gazdei generatoare), indicator „destinația nu răspunde” (dst_bytes = 0) și raportul încărcărilor. Clasele rare (Worms, Shellcode, Backdoor, Analysis) au primit ponderi per eșantion = $(n_{max}/n_c)^{0.5}$ — rădăcina pătrată ridică clasele mici fără să distrugă precizia pe cele mari. Pentru componenta kNN de la Nivelul 3 am folosit log1p + standardizare (distanțele sunt dominate altfel de octeți).

2. Modelele pe niveluri

Nivelul 1 (binar). LightGBM (≤1200 arbori, lr 0.05, 63 frunze, early stopping), validare încrucișată stratificată 5-fold, iar predicția pe test = media celor 5 modele. Pragul de decizie ales pe predicțiile out-of-fold pentru F1 maxim (prag 0.49).

Nivelul 2 (10 clase). LightGBM multiclasă cu ponderile de clasă de mai sus, 5-fold. Macro F1 tratează egal fiecare clasă, așa că după antrenare am căutat (coordinate ascent pe predicțiile out-of-fold) un multiplicator per clasă al probabilităților care maximizează macro F1 — mută frontierele de decizie spre clasele rare.

Nivelul 3 (open-set). Clasificator LightGBM pe cele 7 clase cunoscute (aceeași rețetă ca la nivelul 2). unknown_score = medie ponderată de ranguri (normalizate în [0,1]) a patru semnale: (a) 1 − probabilitatea maximă, (b) entropia distribuției de probabilitate, (c) distanța medie la cei mai apropiați 10 vecini din train în spațiul log-standardizat, (d) un clasificator train-vs-test (fără etichete): train și test sunt din aceeași distribuție cu excepția claselor noi, deci fluxurile care „arată a test” sunt candidați la Unknown. Ponderile au fost alese printr-o simulare leave-one-class-out: pe rând am ascuns fiecare clasă de atac din train, am rărit-o la ~2% în validare (prevalență realistă) și am ales combinația de ponderi cu AUROC mediu maxim. Pragul pentru eticheta Unknown: marcăm cele mai suspecte 1.7% fluxuri din test — fracția estimată din diferența de dimensiune între train-ul nivelului 3 (~139,3k) și cel al nivelului 2 (~141,7k), adică rândurile claselor scoase. Simularea a arătat că macro F1 pe 8 etichete e aproape plat între 1% și 2%, deci alegerea e robustă.

3. Experimente și testare

Nivel	Validare (out-of-fold)	Scor pe test	Timp
1 — F1 binar	0.9601	0.9618	38.5 s
2 — Macro F1 (10)	0.6143 → 0.6235 (scalare)	0.6299	139.3 s
3 — 0.6·F1 + 0.4·AUROC	AUROC simulat 0.8815	0.7101 (blend) / 0.7162 (entropie)	242.2 s

Validare: 5-fold stratificat pe train pentru toate nivelurile, iar pentru Nivelul 3 simularea leave-one-class-out descrisă mai sus (AUROC mediu per semnal: 1-maxprob 0.81, entropy 0.83, knn 0.61, adversarial 0.78). Clasele cele mai slabe la nivelul 2: Backdoor 0.17, Analysis 0.19, DoS 0.50 — fluxurile Analysis/Backdoor/DoS au adesea vectori de caracteristici identici cu etichete diferite, deci niciun model nu le poate separa complet.

Ce nu a mers: (1) Regresia logistică din starter kit pe date brute — mult sub arbori, sensibilă la scara octeților. (2) Numărarea duplicatelor exacte (un vector apare în test mai des decât prezice train-ul → clasă nouă): AUROC ≈ 0.47, nu ajută. (3) Distanța kNN singură: bună când clasa ascunsă e diferită (Generic, AUROC 0.91), dar sub hazard pentru clasele noi care seamănă cu DoS/Exploits — de aceea ponderea ei a fost redusă. (4) Ponderile alese de simulare nu s-au transferat perfect: la Nivelul 3 entropia singură a fost la fel de bună ca blend-ul, așa că am trimis ambele variante.

4. Concluzii și utilizarea AI

Boosting pe arbori + ponderare a claselor + ajustarea pragurilor pe predicții out-of-fold a dat cel mai mult. La open-set, incertitudinea clasificatorului (entropia) a fost cel mai stabil semnal, iar semnalele de densitate ajută doar când clasele noi sunt diferite de cele cunoscute.

Utilizarea AI: Am folosit AI-ul Claude de la Anthropic pentru ghidare.